

线性回归

简单介绍线性回归

是一种预测模型，利用各个特征的数值去预测目标值。线性回归的主要思想是给每一个特征分配一个权值，最终的预测结果是每个特征值与权值的乘机之和再加上偏置。所以训练的目标是找到各个特征的最佳权值和偏置，使得误差最小。线性回归的假设前提是噪声符合正态分布。

线性回归的损失函数 && 为什么使用

线性回归

求解方法

标准方程

$$\theta = (X^T * X)^{-1} * X^T * y$$

- 特点:
 - 要求 $X^T * X$ 可逆
 - 适用于特征数量少的情况, 比如10000个一下
 - 时间复杂度约为 $O(n^3)$

梯度下降

- 方法
 - 随机初始化 θ_j 的值
 - 针对损失函数 $J(\theta)$, 分别计算 θ_j 的偏导数
 - 根据下式同时更新 θ_j , 直到梯度下降为0, $J(\theta)$ 收敛:

$$\theta_j = \theta_j - a * \frac{\partial J(\theta)}{\partial \theta_j}$$

- 特点
 - 适用于特征数量比较大的训练集
 - 随机初始值的不同, 目标函数可能会收敛到不同的值, 即局部最优值(使用随机梯度下降可以解决这个问题).不过线性回归和逻辑回归的损失函数MSE都是凸函数, 只有一个全局最优值.
 - 超参数学习率 a
 - 若太小, 则需要训练更长时间才能收敛
 - 若太大, 则可能左右横跳, 无法收敛
 - 需要对特征进行特征缩放
 - 不做特征缩放的话, 尽管也可以收敛, 但是会耗费更多的训练时间
 - 方法
 - 归一化(min-max normalization)

特点: 对异常值敏感

- 标准化(Z-score Normalization)

- 种类

- 批量梯度下降: 在每轮迭代计算梯度的时候需要使用全部的训练数据
 - 如果损失函数不规则, 不是凸函数, 有可能陷入局部最优解
- 随机梯度下降: 在每轮迭代计算梯度的时候仅使用一个训练样本
 - 如果损失函数不规则, 不是凸函数, 可以跳出局部最优
 - 但是即使达到了全局最优点, 也无法收敛在那里, 因为它会一直跳动
 - 因此可以不断地改变学习率(步长)来进行优化, 这个过程叫做模拟退火
- 小批量梯度下降:
 - 介于批量梯度下降和随机梯度下降之间, 即仅使用一部分数据进行梯度计算

多项式回归

遇到非线性数据的时候, 可以将每个特征的幂次方作为一个新的特征, 然后使用线性模型 $wx+b$ 进行训练

- 特点
 - 可以处理非线性数据
 - 增加模型的复杂度
 - 特征的幂次方越大, 越有可能过拟合, 因此可以加入正则化罚项

正则线性模型

为了减少过拟合, 可以对模型进行正则化. 比如, 将多项式模型正则化的简单方法就是降低多项式的阶数.

对线性模型而言, 正则化通常通过约束模型的权重来实现, 比如使高阶特征的权重约等于0, 即可使模型更简单.

岭回归

加入权重向量的L2范数的平方的一半

$$\lambda \sum_{i=1}^n \theta_i^2$$

- 特点
 - 超参数 λ 控制的是对模型进行正则化的程度.
 - 一般而言, 使用正则化的时候均需要进行特征缩放

套索回归(LASSO回归)

加入权重向量的L1范数

$$\lambda \sum_{i=1}^n |\theta_i|$$

- 特点
 - 比使用L2范数更能完全消除不重要的特征, 即特征权重置为0(L2范数只是让权重约等于0)

岭回归与套索回归的对比

岭回归是个不错的默认选择, 但是如果你认为时机用到的特征只有少数几个, 那就应该更倾向于套索回归或弹性网络, 因为它们会将无用特征的权重降为0.